

Documento Técnico de Arquitectura: Orquestación Multi-Agente Distribuida

Módulo 2: Arquitectura Agéntica Empresarial y Patrón Manager-Worker en n8n
Entregable Técnico: Checkpoint de Pre-entrega 2

1. Información General del Proyecto y Repositorio de Archivos

Campo	Detalle Técnico / Registro
Estudiante / Autor:	Erick Miranda
Nombre del Archivo PDF:	PreEntrega_Modulo2_MirandaErick.pdf
Patrón de Diseño:	Manager-Worker Distribuido con Triage Semántico y Sub-workflows
Motor de Orquestación:	n8n Workflow Automation con AI Agent LangChain Nodes (modelo Google Gemini 3.1 Flash Lite)
Canal de Auditoría / Persistencia:	Google Sheets — planilla "Base_Datos_SaaS_Modulo2" (hojas Clientes_Metricas y Manager_Audit_Logs)

Enlace a la Carpeta de Google Drive (Archivos JSON de Exportación):

URL de Google Drive:
https://drive.google.com/drive/folders/1rV7DK_mNo4iZsdjmV28XgCL4xMH3vHfT?usp=sharing

- manager_modulo2_miranda_erick.json (Orquestador principal y enrutador)
- worker1_modulo2_miranda_erick.json (Especialista en Análisis de Datos)
- worker2_modulo2_miranda_erick.json (Especialista en Redacción y Comunicación)

URL de la Hoja de Cálculo (Google Sheets — base de datos y auditoría):
https://docs.google.com/spreadsheets/d/1zPvD_cHdcU7tbaLO68vrXmnCnMSIWkOT70ZrFFpmp5I/edit?usp=sharing

2. Resumen Ejecutivo y Objetivos de la Arquitectura

El presente documento consolida la arquitectura multi-agente distribuida correspondiente al Módulo 2 del programa técnico. Su objetivo central es erradicar el antipatrón del "Workflow Mono-Bloque" (flujo espagueti monolítico), migrando de un agente centralizado hacia un ecosistema modular de microservicios agénticos organizado bajo el patrón Manager-Worker.

La solución implementa un flujo orquestador central (Manager) que recibe solicitudes heterogéneas vía Webhook, ejecuta un triaje semántico mediante un agente clasificador (AI Intent Classifier, sobre el modelo Google Gemini 3.1 Flash Lite) bajo una taxonomía cerrada, limpia los metadatos innecesarios para evitar el "Pasillo de la Muerte" por Data Stuffing, delega síncronamente la tarea a sub-workflows especializados independientes (Workers) y consolida un registro de trazabilidad en una hoja de cálculo de Google Sheets para auditoría corporativa. Adicionalmente, el Worker de análisis de datos consulta en tiempo real una planilla de métricas de clientes mediante function calling, evitando que el modelo alucine cifras.

3. Arquitectura del Sistema y Roles Funcionales

3.1. Workflow Manager (Orquestador Central) — manager_modulo2_miranda_erick.json

El Manager actúa como el cerebro estratégico del ecosistema digital. No procesa las tareas técnicas en profundidad; su responsabilidad exclusiva es interpretar la intención, preparar el contrato mínimo de datos, delegar la ejecución y gestionar la vía de retorno.

- **Webhook Trigger:** Recibe el ticket de soporte o consulta comercial vía POST sobre la ruta /manager-webhook, con responseMode configurado en nodo de respuesta separado.
- **AI Intent Classifier:** Agente de razonamiento semántico (Google Gemini 3.1 Flash Lite + Structured Output Parser) que clasifica la petición en una taxonomía cerrada estricta: DATA_ANALYSIS, COMMUNICATION_DRAFT o FALLBACK, devolviendo únicamente {"categoria": "..."}.
- **Switch Router:** Nodo determinista de coste computacional cero (n8n Switch) con dos reglas explícitas (DATA_ANALYSIS y COMMUNICATION_DRAFT) y una salida adicional de fallback para cualquier categoría no reconocida.
- **Sanitize for Worker 1 / Sanitize for Worker 2:** Dos nodos Set independientes ("Sanitize for Worker 1" y "Sanitize for Worker 2") que filtran metadatos pesados y construyen el contrato mínimo viable (ticket_id, customer_name, query, target_worker) para cada Worker.
- **Execute Worker 1 (Data Analyst) / Execute Worker 2 (Communication):** Invocan a los sub-workflows worker1_modulo2_miranda_erick y worker2_modulo2_miranda_erick respectivamente, con la propiedad waitForSubWorkflow: true (pausa síncrona activa).
- **Fallback / Human Escalation:** Rama de escape que marca el ticket con status: "escalated_to_human" y worker_invoked: "HUMAN_SUPERVISOR", conservando la consulta original (raw_query) para revisión manual.
- **Consolidate Audit Log:** Nodo Set que unifica la respuesta de cualquier rama (Worker 1, Worker 2 o Fallback) en un registro homogéneo con audit_id (\$execution.id), timestamp, ticket_id, worker_invoked, status y response_payload.
- **Append row in sheet:** Persiste el registro de auditoría anterior en la hoja "Manager_Audit_Logs" de la planilla Base_Datos_SaaS_Modulo2 (operación append), mapeando cada campo a su columna correspondiente en español.
- **Respond to Webhook:** Devuelve la respuesta HTTP 200 con el JSON consolidado al cliente o sistema consumidor.

3.2. Worker 1: Sub-workflow Especialista en Análisis de Datos — worker1_modulo2_miranda_erick.json (DATA_ANALYSIS)

Especialista quirúrgico encapsulado en un lienzo separado. Su tarea atómica es extraer datos reales del cliente, calcular métricas de consumo y emitir un diagnóstico de negocio, evitando que el modelo invente cifras.

- **Execute Workflow Trigger:** Punto de enlace nativo que recibe el contrato de entrada (ticket_id, customer_name, query, target_worker) desde el Manager.
- **AI Data Specialist + Herramienta Google Sheets:** Agente (Google Gemini 3.1 Flash Lite) que analiza la consulta y, mediante la herramienta "Get row(s) in sheet in Google Sheets", consulta en vivo la hoja Clientes_Metricas de la planilla Base_Datos_SaaS_Modulo2 para fundamentar su diagnóstico con datos reales (grounding). Devuelve un JSON estructurado con summary, metrics_found, priority_level (HIGH/MEDIUM/LOW) y diagnostic.
- **Control de Fallos y Formateador de Salida:** Implementa bifurcación por error (onError: continueErrorOutput) mediante un nodo IF que evalúa la existencia de \$json.error, asegurando la entrega de un JSON estandarizado con status: "success" o status: "error".

3.3. Worker 2: Sub-workflow Especialista en Redacción y Comunicación — worker2_modulo2_miranda_erick.json (COMMUNICATION_DRAFT)

Especialista enfocado exclusivamente en la redacción ejecutiva corporativa (Email / Message Drafting). Por directriz de arquitectura y seguridad (Human-in-the-Loop), este Worker no despacha el correo de forma impulsiva, sino que estructura el asunto, saludo, párrafos del cuerpo y llamada a la acción en un esquema formal.

- **Execute Workflow Trigger:** Disparador de ejecución acoplado al Manager, con el mismo contrato de entrada que el Worker 1.
- **AI Copy Specialist:** Agente (Google Gemini 3.1 Flash Lite) parametrizado con directrices de tono corporativo B2B, empatía, concisión y orientación a resolución de incidencias. Responde con subject, greeting, body_paragraphs (array), closing y action_required_by_client (boolean).
- **Format Success Response / Format Error Contingency:** Mismo patrón de control de fallos que el Worker 1 (nodo IF sobre \$json.error), retornando los bloques de comunicación estructurados o un JSON de contingencia con status: "error".

3.4. Vía de Escape / Fallback (Human-in-the-Loop)

Para prevenir que solicitudes fuera de alcance (out-of-scope), consultas ambiguas o casos de alta fricción legal/comercial causen alucinaciones en el modelo o bloqueos en el flujo, se configuró una rama de escape dedicada (nodo "Fallback / Human Escalation"). Esta ruta marca el ticket con estado escalated_to_human y asigna al supervisor humano el procesamiento manual, manteniendo la integridad del pipeline.

4. Especificación Técnica de Contratos de Interfaz (Handoff de Datos)

La transferencia de estado entre el Manager y los Workers se rige bajo contratos JSON estrictos y predecibles, evitando la contaminación del contexto:

Handoff Manager → Workers (Payload Mínimo Viable)

```
{
  "ticket_id": "TCK-1001",
  "customer_name": "Empresa Demo SA",
  "query": "Analizar consumo y diagnosticar estado...",
  "target_worker": "worker1_data_analyst"
}
```

Retorno Worker 1 → Manager (Salida Estructurada de Análisis)

```
{
  "status": "success",
  "worker_name": "worker1_data_analyst",
  "ticket_id": "TCK-1001",
  "timestamp": "2026-08-16T01:10:00Z",
  "data": {
    "summary": "Consumo de cuota elevado al 88%",
    "metrics_found": ["88% API quota", "MRR $1,200 USD"],
    "priority_level": "HIGH",
    "diagnostic": "Requiere upgrade inmediato a Enterprise Plus."
  }
}
```

Retorno Worker 2 → Manager (Salida Estructurada de Redacción)

```
{
  "status": "success",
  "worker_name": "worker2_comm_specialist",
  "ticket_id": "TCK-1003",
  "timestamp": "2026-08-16T01:10:00Z",
  "data": {
    "subject": "Agradecimiento y Sesión de Onboarding VIP",
    "greeting": "Estimado equipo de Fintech Horizons Inc,",
    "body_paragraphs": [
      "Agradecemos su preferencia por nuestra solución SaaS...",
      "Hemos reservado un cupo preferencial para su onboarding."
    ],
    "closing": "Atentamente, Soporte Corporativo",
    "action_required_by_client": false
  }
}
```

Salida Fallback / Auditoría (Consolidación Final — fila en Manager_Audit_Logs)

```
{
  "audit_id": "exec_98432",
  "timestamp": "2026-08-16T01:10:00Z",
  "ticket_id": "TCK-9999",
  "worker_invoked": "HUMAN_SUPERVISOR",
  "status": "escalated_to_human",
  "response_payload": {
    "reason": "Intención fuera de taxonomía estándar",
    "raw_query": "Consulta no estructurada..."
  }
}
```

5. Mitigación de Antipatrones y Resiliencia Empresarial

Antipatrón Identificado	Riesgo Operativo	Mecanismo de Mitigación Implementado
Workflow Mono-Bloque	Flujo espagueti ingobernable, imposible de mantener en equipo y saturación de memoria.	Encapsulamiento de lógica en lienzos separados (sub-workflows) invocados con el nodo Execute Workflow.
Pasillo de la Muerte (Data Stuffing)	Arrastre de payloads masivos, headers y binarios hacia el LLM, disparando el costo de tokens y latencia.	Nodos Set ("Sanitize for Worker 1/2") inmediatamente antes de la delegación, transmitiendo solo 4 variables críticas.
Bloqueo Asíncrono / Carrera	El Manager continúa su ejecución sin esperar al Worker, retornando variables vacías o undefined.	Configuración explícita de waitForSubWorkflow: true en los nodos Execute Worker 1 y Execute Worker 2.
Fallo Silencioso en Worker	Si la API del LLM o base de datos falla, el Worker muere y congela la ejecución del Manager.	Nodo IF ("Check Execution Error") con onError: continueErrorOutput y entrega garantizada de JSON con status: "error" y error_message.
Alucinación de Datos	El agente analista inventa cifras de consumo o facturación al no tener acceso a datos reales del cliente.	Herramienta "Get row(s) in sheet in Google Sheets" (function calling) que consulta la hoja Clientes_Metricas en tiempo real antes de diagnosticar.

6. Persistencia y Log de Auditoría

La observabilidad del sistema se garantiza mediante el nodo "Consolidate Audit Log", que genera una traza unificada, y el nodo "Append row in sheet", que la escribe en Google Sheets:

- **audit_id**: Identificador único de ejecución inmutable (\$execution.id), mapeado a la columna "ID de Auditoría".
- **timestamp**: Registro temporal ISO 8601 exacto de la operación, columna "Marca de Tiempo".
- **ticket_id**: Identificador unívoco del ticket procesado, columna "ID de Ticket".
- **worker_invoked**: Nombre del sub-workflow o supervisor que atendió la solicitud, columna "Proceso Invocado".
- **status**: Estado final de la transacción (success, error o escalated_to_human), columna "Estado".
- **response_payload**: Contenido semántico o de datos devuelto, columna "Datos de Respuesta".

Toda la persistencia del proyecto —tanto la fuente de métricas de clientes que consulta el Worker 1 (hoja Clientes_Metricas) como el log de auditoría que escribe el Manager (hoja Manager_Audit_Logs)— vive en una única planilla de Google Sheets: Base_Datos_SaaS_Modulo2.

Base_Datos_SaaS_Modulo2

Archivo Editar Ver Insertar Formato Datos Herramientas Gemini Extensiones Ayuda

100% 123 Roboto 10 B I A

H1 Estado de Cuenta

	A	B	C	D	E	F	G	H	I
1	ID de Ticket	Nombre del Cliente	Plan	MRR Mensual (USD)	Cuota API (%)	Puntaje de Retención	# Incidentes Abiertos	Estado de Cuenta	Fecha de Último Pago
2	TCK-1001	Empresa Demo SA	Enterprise Pro	1200	88%	0,94	1	ACTIVE	1/08/2026
3	TCK-1002	Logistica Global SRL	Scale Plan	450	96%	0,62	4	OVER_LIMIT	28/07/2026
4	TCK-1003	Fintech Horizons Inc	Starter	99	35%	0,98	0	ACTIVE	10/08/2026
5	TCK-1004	Retail Smart Ltd	Enterprise Pro	2500	92%	0,71	2	AT_RISK	5/08/2026
6	TCK-1005	BioHealth Latam	Scale Plan	600	45%	0,99	0	ACTIVE	12/08/2026

Base_Datos_SaaS_Modulo2

Archivo Editar Ver Insertar Formato Datos Herramientas Gemini Extensiones Ayuda



100% 123 Predet... 10 B I A


C8

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	ID de Auditoría	Marca de Tiempo	ID de Ticket	Proceso Invocado	Estado	Datos de Respuesta							
2	363	2026-08-16T00:52:24.91	TCK-1001	worker1_data_analyst	success	["metrics_found":["Puntaje de Retención: 0.94","MRR Mensual: 1200 USD","Incidentes Abiertos: 1","Estado de Cuenta: ACTIVE"],"							
3	369	2026-08-16T01:03:02.96	TCK-1003	worker2_comm_specialist	success	["subject":"Bienvenida y activación de Sesión VIP de Onboarding - Fintech Horizons Inc (Ref: TCK-1003)","greeting":"Estimados colegas de F							
4	378	2026-08-16T01:07:33.05	TCK-9999	HUMAN_SUPERVISOR	escalated_to	["reason":"Intención fuera de taxonomía estándar o solicitud de baja confianza","raw_query":"¿Cuál es la receta para hacer pizza napolitana e							
5													
6													
7													

7. Evidencias Visuales de la Arquitectura y Ejecución (Screenshots)

Instrucciones: Reemplazar los recuadros delimitados a continuación pegando las capturas de pantalla de tu entorno de n8n y Postman.





raw JSON Schema Beautify

```
1 {
2   "ticket_id": "TCK-9999",
3   "customer_name": "Usuario Desconocido",
4   "query": "¿Cuál es la receta para hacer pizza napolitana en horno de leña?"
5 }
```

Body 200 OK • 18.55 s • 869 B

{ } JSON Preview Visualize

```
1 {
2   "ID de Auditoría": "378",
3   "Marca de Tiempo": "2026-08-16T01:07:33.055-03:00",
4   "ID de Ticket": "TCK-9999",
5   "Proceso Invocado": "HUMAN_SUPERVISOR",
6   "Estado": "escalated_to_human",
7   "Datos de Respuesta": {
8     "reason": "Intención fuera de taxonomía estándar o solicitud de baja
9               confianza",
10    "raw_query": "¿Cuál es la receta para hacer pizza napolitana en horno de
11                 leña?"
12  }
13 }
```

8. Conclusiones y Próximos Pasos (Hacia el M11)

La implementación de esta arquitectura distribuida sienta las bases sólidas para las siguientes etapas del proyecto integrador. La modularidad alcanzada permitirá acoplar en futuros hitos bases vectoriales para RAG avanzado (Pinecone / Qdrant), agentes con herramientas de ejecución autónoma (ReAct), memoria persistente a largo plazo y conectores multicanal (Slack, WhatsApp, Gmail), sin necesidad de reescribir el núcleo del orquestador. En síntesis, el patrón Manager-Worker validado en este checkpoint —ya con grounding real sobre Google Sheets— no es un fin en sí mismo, sino la base de gobernanza sobre la cual se construirá la escalabilidad del sistema hacia el Módulo 11.